

Engenharia de Confiabilidade do Google (SRE)

Monitoração Agregada e Princípios Fundamentais

Professor: Me. Sergio Souza Novak

Faculdade de Engenharia de Software
Universidade de Rio Verde



- 1 Introdução à Monitoração SRE
- 2 White-box vs. Black-box
- 3 Os 4 Sinais de Ouro
- 4 SLOs e Monitoração
- 5 Alertas e Ruído
- 6 Monitoração Agregada
- 7 Distribuição de Dados e Percentis
- 8 Dashboards e Processo
- 9 Conclusão

Definição de Monitoração no Google

O que é monitoração?

Coleta, processamento, agregação e visualização de dados quantitativos em tempo real sobre um sistema.



Figura: Dashboard

- **Visibilidade:** Saber se o sistema está "vivo".
- **Análise:** Entender o comportamento sob carga.
- **Resposta:** Atuar proativamente antes da falha total.

Princípio SRE

Se você não consegue medir, você não consegue gerenciar nem melhorar a confiabilidade.

DASHBOARD MODERNO




Figura: Dashboard

Dashboard Kubernetes



Figura: Dashboard

Dashboard Itaipú





Figura: Interpretação automática por software



Figura: Interpretação humana

Definição

A monitoração é um mecanismo utilizado para acompanhar a **saúde** e a **disponibilidade** de um sistema ao longo do tempo.

Problema da abordagem tradicional

Um sistema que exige que uma pessoa leia um email e interprete manualmente um alerta possui uma falha fundamental.

Boa prática

A interpretação dos eventos deve ser realizada por **software**. Os seres humanos devem ser notificados apenas quando **uma ação precisa ser tomada**.





Figura: Alerta

Alertas

Indicam que um ser humano deve tomar uma **ação imediata** para evitar ou resolver um problema crítico no sistema.

Exemplos

- Servidor fora do ar
- Banco de dados indisponível
- Uso extremo de CPU ou memória

Board

Release



Quick Filters ▾

TO DO 5

Engage Jupiter Express for outer solar system travel

SPACE TRAVEL PARTNERS

✓ ⬆ 5 TIS-25

Create 90 day plans for all departments in the Mars Office

LOCAL MARS OFFICE

➕ ⬇ 9 TIS-12

Engage Saturn's Rings Resort as a preferred provider

SPACE TRAVEL PARTNERS

➕ ⬆ 3 TIS-17

Enable Speedy SpaceCraft as the preferred

IN PROGRESS 5

Requesting available flights is now taking > 5 seconds

SEESPACEEZ PLUS

📅 ⬆ 3 TIS-8

Engage Saturn Shuttle Lines for group tours

SPACE TRAVEL PARTNERS

✓ ⬆ 4 TIS-15

Establish a catering vendor to provide meal service

LOCAL MARS OFFICE

📅 ⬆ 4 TIS-15

Engage Saturn Shuttle Lines for group tours

CODE REVIEW 2

Register with the Mars Ministry of Revenue

LOCAL MARS OFFICE

📅 ⬆ 3 TIS-11

Draft network plan for Mars Office

LOCAL MARS OFFICE

✓ ⬆ 3 TIS-15

DONE 8

Homepage footer uses an inline style - should use a class

LARGE TEAM SUPPORT

➕ ⬆ TIS-68

Engage JetShuttle SpaceWays for travel

SPACE TRAVEL PARTNERS

📅 ⬆ 5 TIS-23

Engage Saturn Shuttle Lines for group tours

SPACE TRAVEL PARTNERS

✓ ⬆ TIS-15

Establish a catering vendor to provide meal service

LOCAL MARS OFFICE

Tickets

Indicam que uma ação humana será necessária, porém **não imediatamente**.

Interpretação

O sistema não consegue resolver o problema automaticamente, mas existe tempo suficiente para que a situação seja tratada posteriormente sem causar danos.

Exemplos

- Disco com alto nível de utilização
- Atualização de software necessária
- Manutenção preventiva

Logging

Consiste no registro de eventos do sistema para **diagnóstico, auditoria e investigação**.

Característica

Essas informações normalmente não precisam ser analisadas imediatamente por um ser humano.

Exemplos

- Registro de acessos ao sistema
- Histórico de erros
- Logs de operações executadas

Saída de Monitoração: Logs

```
/home/tecnosin/virtualenv/backend-tomai/3.7/lib/python3.7/site-packages/pymysql/_auth.py:9: CryptographyDeprecationWarning: Python 3.7 is no longer supported by the Python core team
and support for it is deprecated in cryptography. The next release of cryptography will remove support for Python 3.7.
  from cryptography.hazmat.backends import default_backend
Erro ao inserir dados: (pymysql.err.OperationalError) (1045, "Access denied for user 'tecnosin_tomai-novo-user'@'flora.tdnx.net' (using password: YES)")
(Background on this error at: https://sqlalche.me/e/14/e3q8)
Erro ao inserir dados: (pymysql.err.OperationalError) (1045, "Access denied for user 'tecnosin_tomai-novo-user'@'flora.tdnx.net' (using password: YES)")
(Background on this error at: https://sqlalche.me/e/14/e3q8)
Error: (pymysql.err.OperationalError) (1045, "Access denied for user 'tecnosin_tomai-novo-user'@'flora.tdnx.net' (using password: YES)")
(Background on this error at: https://sqlalche.me/e/14/e3q8)
/home/tecnosin/virtualenv/backend-tomai/3.7/lib/python3.7/site-packages/pymysql/_auth.py:9: CryptographyDeprecationWarning: Python 3.7 is no longer supported by the Python core team
and support for it is deprecated in cryptography. The next release of cryptography will remove support for Python 3.7.
  from cryptography.hazmat.backends import default_backend
[2025-09-27 17:25:41,904] ERROR in app: Exception on /login [POST]
Traceback (most recent call last):
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/engine/base.py", line 3361, in _wrap_pool_connect
    return fn()
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/pool/base.py", line 327, in connect
    return _ConnectionFairy._checkout(self)
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/pool/base.py", line 894, in _checkout
    fairy = _ConnectionRecord.checkout(pool)
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/pool/base.py", line 493, in checkout
    rec = pool._do_get()
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/pool/impl.py", line 146, in _do_get
    self._dec_overflow()
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/util/langhelpers.py", line 72, in __exit__
    with_traceback=exc_tb,
  File "/home/tecnosin/virtualenv/backend-tomai/3.7/lib64/python3.7/site-packages/sqlalchemy/util/compat.py", line 211, in raise_
```

Figura: Log

Por que monitorar?

- **Alertas:** Notificar quando há problemas que exigem intervenção humana.
- **Depuração (Debugging):** Fornecer contexto para encontrar a causa raiz.
- **Análise de Longo Prazo:** Identificar tendências de uso e capacidade.
- **Dashboarding:** Visualização rápida de saúde para stakeholders.



Monitoração é a Base

Todo o trabalho de SRE (Resposta, Mudança, Capacidade) depende de dados sólidos de monitoração.

Foco no Sintoma Externo

Observa o sistema de fora, simulando a experiência do usuário final.

- **Vantagem:** Descobre se o serviço está quebrado *agora*.
- **Desvantagem:** Não explica *por que* está quebrado.
- **Uso Típico:** Paging (Alertas críticos de disponibilidade).

Foco no Interior

Métricas expostas pela própria aplicação: logs, contadores, estados de CPU, latência interna.

- **Vantagem:** Permite monitorar componentes internos que ainda não falharam externamente.
- **Diagnóstico:** Essencial para depurar problemas de performance e gargalos silenciosos.
- **Fonte:** Instrumentação de código (Ex: Prometheus, Stackdriver).

Comparação: Quando Usar cada Uma?

Atributo	Black-box	White-box
Visão	Externo/Usuário	Interno/Código
Propósito	Alerta de crise	Depuração/Capacidade
Sensibilidade	Alta (impacto direto)	Muito Alta (m detalhes)

Regra de Ouro

Use Black-box para saber *o quê* está errado. Use White-box para saber *onde* está o erro.

1. Latência



Definição

O tempo que leva para atender a uma requisição.

- **Atenção:** Monitore separadamente a latência das **requisições de sucesso** e das **requisições de erro**.
- *Exemplo:* Um erro 500 rápido pode mascarar uma latência terrível em requisições de sucesso se você olhar apenas a média global.

2. Tráfego



Definição

A demanda que o sistema está recebendo.

- **Sistemas HTTP:** Requisições por segundo (RPS).
- **Streaming:** Taxas de entrada/saída de dados.
- **Armazenamento:** I/O operations.

Definição

A taxa de requisições que falharam.

- **Explícitos:** Status 500, timeouts.
- **Implícitos:** Resposta 200 que contém conteúdo de erro ou está vazia.
- **Incorretos:** O servidor configurou o código de retorno errado.

4. Saturação

Definição

Quão "cheio" está o sistema em relação aos seus recursos finitos.


- **Métricas:** Memória, CPU, threads em espera, largura de banda.
- **Aviso:** Muitos sistemas sofrem degradação de performance muito antes de atingirem 100% de saturação.

Latência

Tráfego

Erros


Saturação



Definição


SLI (Service Level Indicator) é uma métrica que mede o comportamento real do sistema.

- Latência de requisições
- Taxa de erros
- Disponibilidade do serviço



- **SLI:** Métrica observada no sistema.
- **SLO:** Meta definida para essa métrica.
- **SLA:** Consequências contratuais se o SLO não for cumprido.

Orçamento de Erro (Error Budget)



Conceito


O orçamento de erro é a quantidade de falhas permitidas dentro do SLO.

- Se o SLO é **99.9%**, então temos **0.1% de falha permitida**.
- Esse percentual é o **Error Budget**.
- Se o orçamento acabar, novas mudanças devem parar para focar em estabilidade.

- Não monitore tudo com o mesmo rigor.
- Foque no que **gera valor para o usuário**.
- Evite métricas de "vaidade" (ex: número total de usuários logados não indica se o sistema está rápido).

- ❶ **Páginas (Alertas Instantâneos):** Acordam alguém. Use apenas para problemas críticos e resolvíveis.
- ❷ **Tickets:** Para problemas que precisam de ação, mas não urgentes.
- ❸ **Logs/Dashboards:** Para análise posterior ou tendência.

Alertas: Sintoma vs. Causa



Alerta baseado apenas na causa


“Disco atingiu 80%” pode não causar nenhum problema real no serviço. Isso gera muitos *falsos alarmes*.

Alerta baseado no sintoma

“20% dos envios de e-mail estão falhando”. Isso indica impacto direto para os usuários e deve gerar alerta.

- Todo alerta deve ser **acionável**.
- Se você vê um alerta e ignora, a regra de alerta **deve ser removida**.
- Excesso de alertas irrelevantes esconde os reais incidentes.

O Desafio da Escala




Monitorar mil máquinas individualmente é impossível para humanos.

Agregação

Combine estatísticas de várias instâncias para ver o comportamento do *cluster* como um todo.

Distribuição de Frequência




Definição

A distribuição de frequência mostra quantas vezes valores aparecem em intervalos de uma variável.



Exemplo: alturas, pesos, latência de um sistema, tamanho de peixes.

Distribuição de dados



Definição

Um percentil indica a posição abaixo da qual uma porcentagem dos dados está.


Exemplo:

- $P50 = \text{mediana}$
- $P90 = 90\%$ dos dados estão abaixo desse valor

A Média mente!


Em latência, a média esconde outliers.

- Use ****Percentis (P90, P95, P99)****.
- P99 de 1s significa que 1% das requisições levaram mais de 1s.
- É aqui que os usuários "infelizes" estão escondidos.



Comportamento


Na assimétrica a direita, a média é puxada para cima por outliers, enquanto a mediana permanece mais representativa do comportamento típico.



Comportamento

Na simétrica normal, a média e a mediana são iguais, e ambos representam bem o comportamento típico.


Assimetria à Esquerda



Comportamento

Na assimétrica a esquerda, a média é puxada para baixo por outliers, enquanto a mediana permanece mais representativa do comportamento típico.


Box plots o que é




Comportamento

O box plot mostra a mediana, os quartis e os outliers, permitindo uma visualização rápida da distribuição dos dados.


Box plots o que é




Box plots o que é



Box plots o que é





- Veja padrões semanais e sazonais.

Objetivo

Calcular os percentis de latência (P98 e P99) de um conjunto de requisições.

```
import numpy as np


# Latencias simuladas (em ms)
latencias = np.random.normal(200, 40, 1000)

# Percentis
p98 = np.percentile(latencias, 98)
p99 = np.percentile(latencias, 99)

print("Latencia_P98:", p98)
print("Latencia_P99:", p99)
```

- Cada valor representa o tempo de resposta de uma requisição.
- Percentis mostram o comportamento da cauda da distribuição.

Percentis de Latência




Interpretação

- **P98:** 98% das requisições respondem antes desse tempo.
- **P99:** 99% das requisições respondem antes desse tempo.

Importante em Sistemas Distribuídos

Percentis altos revelam problemas de desempenho que a média esconde.



- **Percentil 98 (P98):** 98% das requisições são mais rápidas que esse valor.
- **Percentil 99 (P99):** 99% das requisições são mais rápidas que esse valor.
- O 1% restante representa as requisições mais lentas.

Exemplo de cálculo

```
import numpy as np

# latencias simuladas em ms
latencias = np.random.normal(200, 40, 1000)

# calculo dos percentis
p98 = np.percentile(latencias, 98)
p99 = np.percentile(latencias, 99)

print("Latencia_P98:", p98)
print("Latencia_P99:", p99)
```

Interpretação

Se P99 = 420 ms, então 99

Definição

O percentil P_k é o valor abaixo do qual estão $k\%$ dos dados de uma distribuição ordenada.



Interpretação

Se $P_{98} = 320\text{ ms}$, então 98% das requisições possuem latência menor ou igual a 320 ms.

- No topo: Disponibilidade global e SLO.
- Abaixo: Os 4 Sinais de Ouro.
- Mais abaixo: Links para playbooks e logs detalhados.

Cada alerta deve ter um link para um **Playbook**.

- O que este alerta significa?
- Quais são os primeiros passos de diagnóstico?
- Quem contatar se escalar?

Alertas do Google

Google Alert Feed Reader




Figura: Alertas do Google

- Comece simples, foque no usuário.
- Alerta sobre **Sintomas**.
- Use **Métricas de Caixa-Branca** para rapidez.
- Monitore para **aprender**, não apenas para consertar.

Obrigado!

Professor Sergio Souza Novak
Engenharia de Qualidade e Confiabilidade