

Atividade Prática — Análise de Logs de Servidor Web

Disciplina: Engenharia de Qualidade e Confiabilidade

Tema: Análise de Logs e Desempenho de Sistemas

Objetivo

Objetivo da Atividade

O objetivo desta atividade é analisar registros de acesso (*logs*) de um servidor Web para identificar padrões de uso, erros de requisição e características de desempenho do sistema. Os alunos deverão utilizar técnicas de análise de dados para:

- interpretar registros de acesso HTTP
- identificar padrões de latência
- analisar erros do servidor
- extrair informações relevantes sobre o comportamento dos usuários

Formato do Log

Cada linha do log representa uma requisição realizada ao servidor. A estrutura geral do registro contém:

- ID da requisição
- endereço IP do cliente
- data e horário da requisição
- método HTTP
- URL requisitada
- protocolo HTTP
- código de status
- tamanho da resposta
- agente do usuário (browser ou robô)

- latência da requisição (ms)

Exemplo de registros de log

```
54.36.149.41 - - [22/Jan/2019:03:56:14 +0330]
"GET /filter/27 HTTP/1.1" 200 30577 "-"
"Mozilla/5.0 (compatible; AhrefsBot/6.1)" "-" 436.23

5.210.140.170 - - [23/Jan/2019:12:43:40 +0330]
"GET /apple-touch-icon-120x120.png HTTP/1.1" 404 33679 "-"
"MobileSafari/604.1 CFNetwork/976 Darwin/18.2.0" "-" 796.76

66.249.66.91 - - [24/Jan/2019:21:17:43 +0330]
"GET /static/images/guarantees/bestPrice.png HTTP/1.1" 304 0 "-"
"Googlebot-Image/1.0" "-" 137.28
```

Leitura dos Dados com Python

Utilize o código abaixo para carregar e processar o arquivo de *log* em um DataFrame do Pandas:

Código para Processamento do Log

```
import pandas as pd
import re

pattern = re.compile(
    r'(?P<ip>\S+) - - ',
    r'\[(?P<time>[^\]]+)\] ',
    r'""(?P<method>\S+) (?P<url>\S+) (?P<protocol>\S+)"" ',
    r'(?P<status>\d+) (?P<size>\d+) ',
    r'""(?P<referer>[^\"]*)"" ',
    r'""(?P<agent>[^\"]*)"" ',
    r'""-"" (?P<latency_ms>[0-9\.]++)'
)

rows = []

with open("access_with_latency.log", "r", encoding="utf-8") as f:
    for line in f:
        # separa id do log
        parts = line.split(",", 1)

        if len(parts) == 2 and parts[0].isdigit():
            log_id = int(parts[0])
            log_part = parts[1].strip().strip('""')
        else:
            log_id = None
            log_part = parts[-1].strip().strip('""')

        match = pattern.search(log_part)

        if match:
            data = match.groupdict()
            data["id"] = log_id
            rows.append(data)

df = pd.DataFrame(rows)
```

Atividade

Os alunos deverão utilizar Python (Pandas, Matplotlib e Seaborn) para analisar o arquivo de log fornecido.

Formato de Entrega da Atividade

Formato obrigatório de entrega

A atividade deverá ser entregue em **dois arquivos PDF distintos**, respeitando obrigatoriamente o seguinte formato:

1. PDF com as respostas da atividade

Este documento deve conter **apenas as respostas objetivas das questões propostas**. As respostas devem ser escritas em texto, explicando os resultados obtidos na análise dos dados.

- Não incluir código neste arquivo.
- As respostas devem ser claras e objetivas.
- Sempre que necessário, interpretar os resultados obtidos nos gráficos ou cálculos.

2. PDF do notebook utilizado

O segundo arquivo deve conter o **notebook completo utilizado para realizar a análise** (por exemplo, Jupyter Notebook ou Google Colab).

Este arquivo deve incluir:

- todo o código utilizado na análise
- geração de gráficos
- processamento do arquivo de log

O notebook deve ser exportado para PDF e entregue com o nome:

`notebook.pdf`

Importante:

- O PDF com as respostas deve conter **somente texto explicativo**.
- O código deve aparecer **apenas no notebook**.
- Trabalhos que não seguirem este formato poderão sofrer desconto na nota.

FORMATO DA ENTREGA DE ATIVIDADE

pdf com o conteúdo as respostas da análise de dados realizada em sala de aula


1. Quantas requisições existem no arquivo de log?
Tem 1001 requisições.

2. Quantos endereços IP diferentes aparecem no log?
O Log tem 7656 ips diferentes.

3. 1. Quantas requisições existem no arquivo de log?
Tem 1001 requisições.

TODAS AS OUTRAS QUESTÕES COM RESPOSTA AQUI NESTE PDF, RESPOSTAS OBJETIVAS, SEM CÓDIGO!!!

pdf com o conteúdo do notebook utilizado: notebook.pdf



Parte 1 — Estrutura dos dados

Responda:

1. Quantas requisições existem no arquivo de log?
2. Quantos endereços IP diferentes aparecem no log?
3. Quais métodos HTTP aparecem no conjunto de dados?
4. Qual o código de status mais frequente?

Parte 2 — Análise de latência

Utilizando gráficos de distribuição:

1. Construa um histograma da latência das requisições.
2. Analise se a distribuição é simétrica ou assimétrica.
3. Existem requisições com latência muito elevada?
4. Qual é o percentil 90 da latência?

Parte 3 — Métodos HTTP

1. Compare a distribuição de latência entre os métodos HTTP.
2. Algum método apresenta maior latência média?
3. Qual método apresenta maior variabilidade?

Parte 4 — Análise de erros e Confiabilidade

Considere os códigos de status HTTP entre 400 e 599 como erros.

1. Quantas requisições resultaram em erro?
2. Calcule a **Taxa de Erro (Error Rate)** utilizando a fórmula:

$$\text{Error Rate} = \frac{\text{Total de Erros}}{\text{Total de Requisições}} \times 100$$

3. Calcule a **Disponibilidade (Availability)** do serviço:

$$\text{Availability} = \frac{\text{Requisições com Sucesso}}{\text{Total de Requisições}} \times 100$$

4. Compare a latência das requisições com erro e das requisições bem-sucedidas. O servidor demora mais para responder erros ou sucessos?

Parte 5 — SRE e SLAs (Service Level Agreements)

A disponibilidade é frequentemente medida em "noves". Com base na tabela abaixo, em qual nível de disponibilidade o servidor se encontra?

Disponibilidade	Tempo fora do ar (por mês)
99%	~7h
99,9%	~43 min
99,99%	~4 min
99,999%	~26 s

1. Se o acordo de nível de serviço (SLA) exigisse 99,9% de disponibilidade, este servidor estaria cumprindo a meta?

Parte 6 — Requisições lentas

Utilizando o percentil 90 de latência:

1. Identifique requisições com latência acima do percentil 90.
2. Quais URLs aparecem com maior frequência nessas requisições?
3. Existem IPs específicos associados a alta latência?

Discussão

Com base nas análises realizadas, responda:

- O servidor apresenta sinais de sobrecarga?
- Existem indícios de acesso automatizado (bots)?
- Quais possíveis melhorias poderiam ser aplicadas para reduzir a latência?