

Resposta a Emergências

Engenharia da Qualidade e Confiabilidade

Prof. Me. Sergio Souza Novak — UniRV

26 de março de 2026




1) Confiabilidade: MTTF e MTTR

Métricas fundamentais:

- **MTTF** — Mean Time To Failure
Tempo médio até a próxima falha
- **MTTR** — Mean Time To Repair
Tempo médio para recuperação
- **Disponibilidade** depende de ambos:


$$A = \frac{\text{MTTF}}{\text{MTTF} + \text{MTTR}}$$

- A métrica **mais crítica** na resposta a emergências é o **MTTR**




2) Seres Humanos Acrescentam Latência

- Humanos introduzem **atrasos** no processo de recuperação:
 - Detecção do alerta
 - Avaliação do problema
 - Tomada de decisão
 - Execução da ação
- **Sistemas automatizados** respondem em milissegundos
- Um sistema com **mais falhas**, mas com recuperação automática, pode ter **maior disponibilidade** que um sistema mais estável, porém dependente de intervenção manual




3) O Manual de Regras (*Runbook*)

- Registrar boas práticas **com antecedência** reduz o MTTR em até **3×**
- **Improvisar** durante uma crise é arriscado e lento
- O *runbook* deve conter:
 - Passos claros e ordenados
 - Critérios de diagnóstico
 - Comandos prontos para uso
 - Escalonamento de responsabilidades
- **Engenheiro treinado + runbook** supera o “herói” improvisado



4) Práticas de Preparação — SRE Google

- Runbooks **não substituem** engenheiros capazes de raciocinar
- Boas práticas do Google SRE:
 - **Manuais de plantão** detalhados e atualizados
 - **Wheel of Misfortune** — simulação de incidentes reais:
 - Um engenheiro age como “engenheiro de plantão”
 - Outro apresenta sintomas de incidente
 - Time aprende a reagir sem pressão real
 - **Postmortems** sem culpa após incidentes
 - Alertas bem calibrados (sem ruído excessivo)



1. A Dinâmica (O "Jogo")



O Mestre (Game Master): Um engenheiro sênior que conhece bem o sistema. Ele escolhe um incidente que já aconteceu de verdade (baseado em um Postmortem antigo).

O Jogador: Um engenheiro (geralmente alguém entrando no rodízio de plantão/on-call).

O Cenário:

- Mestre diz: "São 3 da manhã, seu Pager toca."
- Alerta: Latência no Checkout acima de 500ms.
- Pergunta ao jogador: "O que você faz?"

2. O Encaixe nas Boas Práticas do Google

A. Validação dos Manuais de Plantão (Playbooks)

- Se o jogador diz "Vou olhar o manual" e ele estiver desatualizado ou confuso, o grupo descobre isso na simulação.
- Resultado: O time atualiza o manual imediatamente após o jogo.


B. Redução da "Fadiga de Alerta"

- Durante o jogo, o mestre pode lançar alertas falsos (ruído).
- O jogador aprende a filtrar o que é crítico e o que é distração.
- Resultado: O time aprende a calibrar alertas para que sejam úteis, não irritantes.



5) As coisas quebram — a vida é assim


- Falhas são **inevitáveis** em qualquer sistema ou empresa
- O que diferencia uma organização resiliente é **como as pessoas respondem**
- Uma boa resposta exige:
 - **Preparação** antecipada
 - **Treinamento** periódico, pertinente e prático
 - **Suporte da diretoria e da gerência**
- Investir em testes e treinamentos pode custar **dinheiro, tempo e até uptime** — e vale a pena
- Incidentes bem tratados viram **oportunidades de aprendizado** (postmortems)



6) O que fazer quando os sistemas falham

Protocolo básico de resposta:

- **Não entre em pânico** — você foi treinado para isso
- Lembre-se: *raramente há risco físico*; mantenha a calma
- **Avalie o escopo** do problema antes de agir
- Se sentir sobrecarregado: **chame mais pessoas**
 - Page para o time ou para toda a empresa se necessário
- Siga o **processo de resposta a incidentes** da empresa. Documente as ações tomadas para o **postmortem**




7) Emergência Induzida por Testes

- O Google adota uma abordagem **proativa**: provocar falhas de forma controlada
- Objetivo: observar como os sistemas falham e **melhorar a confiabilidade**
- Na maioria das vezes as falhas controladas ocorrem **conforme planejado**:
 - Sistemas se comportam como esperado
 - Dependências ocultas são reveladas
 - Ações de *follow-up* são documentadas
- Às vezes os resultados **divergem drasticamente** das suposições
- Esses casos são os mais valiosos para o aprendizado



8) Emergência Induzida por Testes




8) Estudo de Caso — Teste no MySQL

Detalhes do teste:

- Alvo: um dos maiores bancos de dados MySQL distribuídos do Google
- Plano: bloquear acesso a **1 banco entre 100**
- Objetivo: revelar **dependências ocultas**

O que aconteceu:

- Minutos após o início: múltiplos serviços externos e internos **ficaram inacessíveis**
- Sistemas em estado **intermitente ou parcialmente disponíveis**
- SRE abortou imediatamente o teste
- *Rollback* das permissões não funcionou de imediato. Acesso totalmente restaurado **em 1 hora** via abordagem alternativa



9) Descobertas e Lições Aprendidas

O que deu certo:

- Serviços afetados **escalaram imediatamente** o problema
- Equipe abortou o teste **sem entrar em pânico**
- Esforços **paralelos** aceleraram a restauração
- Ações corretivas foram **rápidas e completas**


O que aprendemos:

- Compreensão **insuficiente** das dependências entre sistemas
- Processo de resposta a incidentes **não havia sido comunicado** a todos
- Procedimentos de *rollback* **devem ser testados** antes de testes em larga escala
- Testes periódicos são essenciais para **evitar reincidências**




10) Emergência Induzida por Alterações

- O Google realiza **inúmeros testes** em mudanças de configuração
- A escala e complexidade tornam **impossível prever** todas as dependências
- **Detalhes do caso:**
 - Mudança de configuração em infraestrutura de **proteção contra abusos**
 - Implantada globalmente em uma **sexta-feira**
 - Disparou um bug que causou **falhas sucessivas** em toda a frota
 - Serviços internos e externos ficaram simultaneamente indisponíveis
- A infraestrutura interna também depende dos próprios serviços do Google — o impacto foi **cascata**



11) Resposta — Incidente de Configuração

- **Segundos após a mudança:** alertas de monitoração dispararam
- Engenheiros de plantão migraram para **salas de segurança** (quartos de pânico) com acesso de backup à produção
- **5 minutos após:** engenheiro responsável fez **rollback** da mudança ao tomar conhecimento da falha corporativa
- Serviços começaram a se recuperar logo após o rollback
- **10 minutos após:** incidente declarado formalmente; procedimentos internos acionados
- Alguns serviços com bugs não relacionados só se recuperaram **após 1 hora**



12) Descobertas e Lições — Mudanças de Configuração

O que deu certo:

- Monitoração detectou o problema **quase imediatamente**
- Sistemas de comunicação em **banda alternativa** mantiveram a equipe conectada
- Ferramentas de **linha de comando** e acesso alternativo permitiram o rollback
- Infraestrutura **limitou a velocidade** de propagação das falhas (throttling)

Positivo

Monitoração rápida
Comm. alternativa
Rollback disponível
Throttling de falhas
Sorte (diligência)

A melhorar

Canary rigoroso
Alertas calibrados
Treinar ferramentas
Reduzir depend. internas

12) Descobertas e Lições — Mudanças de Configuração

O que aprendemos:

- **Canary incompleto** — palavra-chave rara não foi exercitada
- Mudanças percebidas como “de baixo risco” também precisam de **canary rigoroso**
- Alertas excessivos **sobrecarregaram** os engenheiros de plantão
- Equipe precisava de **maior familiaridade** com ferramentas de backup
- Dependência das próprias ferramentas internas agravaria uma interrupção mais longa

Positivo


Monitoração rápida
Comm. alternativa
Rollback disponível
Throttling de falhas
Sorte (diligência)

A melhorar

Canary rigoroso
Alertas calibrados
Treinar ferramentas
Reduzir depend. internas

13) Emergência Induzida por Processo

- A automação do Google é poderosa — e, às vezes, **rápida demais**
- **Detalhes do caso:**
 - Duas requisições consecutivas de **desativação** foram enviadas para a mesma instalação
 - Um **bug sutil** na automação interpretou resposta vazia como “*todas as máquinas*”
 - Resultado: todas as máquinas enviadas para a fila do **Diskerase** globalmente
 - Discos rígidos limpos; máquinas incapazes de responder a requisições
- **Lição central:** zero pode significar *tudo* — verificações de sanidade são essenciais




14) Resposta e Recuperação — Incidente de Processo

Resposta imediata:

- Page acionado; engenheiros **drenaram o tráfego** das localidades afetadas
- Tráfego redirecionado para instalações maiores (não afetadas)
- **Toda a automação da equipe foi desabilitada** para evitar mais danos
- Em **1 hora**: tráfego completamente desviado; interrupção superada

Recuperação (a parte difícil):

- Congestionamentos de rede tratados em paralelo
- Primeira instalação reconstruída em **3 horas**
- Equipe dividida em 3 grupos com etapas definidas de reinstalação
- **Maioria da capacidade** restaurada em 3 dias; retardatários em 1–2 meses



15) Todos os Problemas Têm Soluções

O que deu certo:

- Instalações **grandes** não foram afetadas (arquitetura diferente)
- Transferência rápida de tráfego; usuários atendidos com latência mínima
- Protocolos de resposta a incidentes **maduros** e bem executados
- Colaboração exemplar entre equipes e geografias



15) Todos os Problemas Têm Soluções


O que aprendemos:

- Automação precisa de **verificações de sanidade** — zero $\neq$ “sem filtro”
- Reinstalação via **TFTP com QoS baixo** é lenta e não confiável em escala
- Infraestrutura de reinstalação deve **suportar cargas excepcionais**
- **Envolva quem disparou o evento** — é quem mais sabe do estado atual
- Após a crise: **registre, limpe e aprenda**



16) Aprenda com o Passado — Postmortems

- **Documente** cada interrupção de serviço com honestidade
- Postmortems eficazes respondem:
 - *O que falhou?* (causa-raiz)
 - *Como evitar?* (tático e estratégico)
 - *Quem é responsável pelo follow-up?*
- **Publique e organize** os postmortems — a história é de todos
- **Atribua responsabilidades** e acompanhe as ações corretivas
- Um bom histórico evita que a **mesma interrupção aconteça duas vezes**




17) Perguntas Difíceis e Testes Proativos

Faça as perguntas “E se...?”:

- E se a **energia do prédio cair**?
- E se o **datacenter ficar às escuras**?
- E se alguém **comprometer seu servidor web**?
- Você tem um **plano**? Você sabe como **reagir**?
- A pessoa ao seu lado poderia fazer o mesmo?


Incentive testes proativos:

- **Teoria** $\neq$ **realidade** — só testando você saberá
- Prefira que a falha ocorra durante um **teste supervisionado** a às 2h da manhã sem aviso e não conte com suposições não verificadas



18) Conclusão — O Ciclo de Melhoria Contínua

- Três emergências, três origens diferentes:
 - **Teste proativo** (MySQL)
 - **Mudança de configuração** (bug de canary)
 - **Automação de desativação** (Diskerase)
- Mas as **respostas tiveram muito em comum**:
 - Sem pânico
 - Convocação de mais pessoas
 - Aprendizado com o passado
 - Documentação e follow-up
 - Testes proativos subsequentes
- O ciclo é **universal** — aplica-se a qualquer empresa, de qualquer porte



Obrigado!

Dúvidas?

